

## Задание 3. К ближайших соседей (kNN)

Курс по методам машинного обучения, 2023-2024, Драгунов Никита

## 1 Характеристики задания

- **Длительность:** 2 недели
- **Кросс-проверка:** 23 балла; в течение 1 недели после дедлайна; нельзя сдавать после жесткого дедлайна
- **Юнит-тестирование:** 17 баллов; Можно сдавать после дедлайна со штрафом в 40%; Публичная часть; PEP8
- **Почта:** ml.cmc@mail.ru
- **Темы для писем на почту:** ВМК.ML[Задание 3][peer-review], ВМК.ML[Задание 3][unit-tests]

**Кросс-проверка:** После окончания срока сдачи, у вас будет еще неделя на проверку решений как минимум **3х других студентов** — это **необходимое** условие для получения оценки за вашу работу. Если вы считаете, что вас оценили неправильно или есть какие-то вопросы, можете писать на почту с соответствующей темой письма

## 2 Описание задания

В настоящем задании вы познакомитесь с алгоритмом k ближайших соседей (k-NN, KNN, kNN) для решения задач классификации и регрессии.

Приведем здесь краткое напоминание о принципе работы kNN. Пусть дана обучающая выборка  $X = (x_i, y_i)$  и функция расстояния  $\rho$ . Требуется классифицировать новый объект  $u$ . Алгоритм k ближайших соседей относит объект  $u$  к тому классу, представителей которого окажется больше всего среди k его ближайших по  $\rho$  соседей:  $\alpha(u; X, k) = \operatorname{argmax}_{y \in Y} \sum_{i=1}^k w_i [y_u^{(i)} = y]$ , где  $y_u^{(i)}$  — метка класса i-го соседа объекта  $u$ . В классическом методе k ближайших соседей все объекты имеют единичные веса:  $w_i = 1$ . Альтернативой данному подходу служат веса, обратно пропорциональные расстоянию между объектами. При решении задачи регрессии ответом алгоритма служит средневзвешенное значение меток  $y_u^{(i)}$  среди k ближайших соседей.

## 3 Кросс-проверка

- **Ссылка на задание:** [ссылка тут](#)

**Внимание!** Отправлять задание нужно в систему во вкладку **KNN (notebook)**.

**Внимание!** Отправлять задание нужно только с расширением `ipynb`! После отправки проверьте корректность загруженного задания в систему, просмотрев глазами загруженное решение (оно автоматически сконвертируется в `html`). Как это сделать, можно найти в [туториале тут](#)

**Внимание!:** Перед сдачей проверьте, пожалуйста, что не оставили в ноутбуке где-либо свои ФИО, группу и так далее — кросс-рецензирование проводится анонимно.

## 4 Юнит-тестирование

- В ходе выполнения задания 1.1 из `jupyter-notebook` вам необходимо реализовать два вида нормализации признаков пространства в модуле `scalers.py`. Первый вид нормализации `StandardScaler` выполняет нормализацию к распределению с нулевым матожиданием и единичной дисперсией. Второй вид нормализации `MinMaxScaler` отображает признаковые описания в отрезок  $[0, 1]$ .

- В ходе выполнения задания 2.1 из jupyter-notebook вам необходимо реализовать две функции в модуле `cross_val.py`. Первая функция `kfold_split` выполняет генерацию индексов обучающей и валидационной выборки для кросс-валидации. Вторая функция `knn_cv_score` выполняет кросс-валидацию для KNN-модели.

Файлы `scalers.py` и `cross_val.py` можно найти в архиве из **шаблона решения** во вкладке **KNN (unit-tests)**. Более подробное описание входных и выходных данных вы найдете в этих файлах. После реализации ваш код можно **протестировать локально (ссылка)**, а затем его необходимо сдать в проверяющую систему (вкладка **KNN (unit-tests)**).

**Замечание:** Запрещается пользоваться библиотеками, импорт которых не объявлен в файле с шаблонами функций.

**Замечание:** Задания, в которых есть решения, содержащие в каком-либо виде взлом тестов, дополнительные импорты и прочие нечестные приемы, будут автоматически оценены в 0 баллов без права пересдачи задания.

## 5 Стиль программирования

### Внимание! Обновление!!!

Начиная с этого задания при выполнении задач типа unit-tests, ML-задания вам необходимо будет соблюдать определенный стиль программирования (codestyle). В данном случае мы выбирали PEP8 как один из популярных стилей для языка Python. Зачем мы это вводим? Хорошая читаемость кода – не менее важный параметр, чем работоспособность кода :) Единый стиль позволяет быстрее понимать код сокомандников (в командных проектах, например), упрощает понимание кода (как другим, так и вам). Также, привыкнув к какому-либо стилю программирования, вам будет проще переориентироваться на другой.

Полезные при изучении PEP8 ссылки, если что-то непонятно, дополнительный материал можно найти самостоятельно в интернете:

- [Официальный сайт PEP8, на английском](#)
- [Небольшое руководство по основам на русском](#)

Требования к PEP8 мы вводим только для заданий с авто-тестами, требований к такому же оформлению ноутбуков нет. Но улучшение качества кода в соответствии с PEP8 в них приветствуется!

**Внимание!!!** В проверяющей системе, при несоответствии прикрепляемого кода PEP8, будет высвечиваться вердикт `Preprocessing failed`. Более подробно посмотреть на ошибки можно, нажав на них:

12.10.2022 `cross_val.py`  
19:22 `scalers.py`

`Preprocessing failed`

# Результат

Время  
работы в  
секундах

`Preprocessing failed: Runtime error`

```
Traceback (most recent call last):
  File "pre.py", line 39, in <module>
    raise RuntimeError(err_message)
RuntimeError: Found 6 errors or warnings in submission.
Detailed info:
scalers.py:6:65: W291 trailing whitespace
scalers.py:17:73: W291 trailing whitespace
scalers.py:31:13: E128 continuation line under-indented for visual indent
scalers.py:38:56: W291 trailing whitespace
scalers.py:44:43: W291 trailing whitespace
scalers.py:80:33: E131 continuation line unaligned for hanging indent
```

Также посылки, упавшие по **code style**, считаются за попытку сдачи и идут в счет общего количества посылок за день.

Проверить стиль программирования локально можно при помощи утилиты `pycodestyle` (в окружении, которое вы ставили, эта утилита уже есть) с параметром максимальной длины строки (мы используем 160 вместо дефолтных 79):

```
pycodestyle --max-line-length=160 your_file_with_functions.py
```

## 6 Тестирование

В cv-gml можно скачать все файлы, необходимые для тестирования, одним архивом. Для этого просто скачайте zip-архив во вкладке **шаблон решения** соответствующего задания и разархивируйте его. Далее следуйте инструкциям по запуску тестирования.

Тесты запускаются с помощью команд:

```
python run.py unittest scalers  
python run.py unittest cv
```